UFRR
UNIVERSIDADE FEDERAL DE RORAIMA
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO
ESPECIALIZAÇÃO EM COMPUTAÇÃO APLICADA NA INDÚSTRIA 4.0

RAFAEL BENZAQUEM NETO

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de Clustering e Deep Learning.

Boa Vista – Roraima,
Janeiro de 2026

RAFAEL BENZAQUEM NETO

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de Clustering e Deep Learning.

Monografia de Pós-graduação *Lato Sensu* apresentada à Especialização em Computação Aplicada na Indústria 4.0 da Universidade Federal de Roraima, como requisito parcial para a obtenção do grau de especialista em computação aplicada na indústria 4.0.

Boa Vista – Roraima,
Janeiro de 2026

Sumário

1. Introdução 1
2. Fundamentação teórica 2
   2.1. Perturbações na Qualidade de Energia 3
   2.2. Aprendizado de Máquina Não Supervisionado: K-Means 3
   2.3. Deep Learning e Autoencoders Convolucionais 3
4. Solução computacional 5
   4.1. Arquitetura da Solução 5
   4.2. Ambiente de Desenvolvimento e Tecnologias 5
   4.3. Pipeline de Processamento e Modelagem 6
      4.3.1. Coleta e Pré-processamento dos Dados 6
      4.3.2. Extração de Características com Autoencoder Convolucional (CAE) 6
      4.3.3. Clusterização e Visualização 6
5. Avaliação experimental 7
   5.1. Planejamento da pesquisa 7
   5.2. Resultados Esperados 7
6. Cronograma 9
7. Referências 10

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de Clustering e Deep Learning.

Rafael Benzaquem Neto[1], Josiane do Couto Rodrigues [1]

[1]Departamento de Ciência da Computação – Universidade Federal de Roraima (UFRR) – Boa Vista – RR – Brasil

rafaelbenzaquem@ulbra.edu.br, josiane.rodrigues@ufrr.br

Resumo. *A modernização das redes elétricas gera volumes massivos de dados de perturbações não rotulados, tornando a análise manual inviável. Este estudo objetiva caracterizar automaticamente esses eventos em subestações de distribuição utilizando dados reais sem supervisão humana. A solução computacional integra Deep Learning via Autoencoders Convolucionais para extração de características e o algoritmo K-Means para o agrupamento dos sinais. A pesquisa processará oscilografias das subestações Sub3 e Sub8, abrangendo normalização, treinamento da rede neural e validação dos grupos formados via métricas de silhueta. Espera-se demonstrar a viabilidade da segregação autônoma de eventos como afundamentos e elevações, filtrando anomalias críticas para auxiliar a tomada de decisão. O trabalho contribui para a resiliência do sistema elétrico ao superar o gargalo da rotulagem manual em cenários de Big Data.*

Abstract. *The modernization of electrical grids generates massive volumes of unlabeled disturbance data, making manual analysis unfeasible. This study aims to automatically characterize these events in distribution substations using real data without human supervision. The computational solution integrates Deep Learning via Convolutional Autoencoders for feature extraction and the K-Means algorithm for signal clustering. The research will process oscillography from substations Sub3 and Sub8, covering normalization, neural network training, and validation of formed groups via silhouette metrics. It is expected to demonstrate the feasibility of autonomous segregation of events such as sags and swells, filtering critical anomalies to aid decision-making. The work contributes to power system resilience by overcoming the manual labeling bottleneck in Big Data scenarios.*

1. Introdução

A modernização dos sistemas de energia elétrica e a transição contínua para o conceito de *Smart Grids* resultaram em uma integração massiva de dispositivos eletrônicos inteligentes, fontes de energia renovável e sistemas de monitoramento avançado (Ukil e Zivanovic, 2014) (Mishra, Subudhi e Jain, 2019). Embora essa evolução tecnológica ofereça maior observabilidade da rede, ela também introduziu novos desafios, particularmente no que tange à Qualidade de Energia (PQ). A proliferação de cargas não lineares e a intermitência de fontes renováveis aumentaram a complexidade das perturbações elétricas, tornando a detecção e classificação desses eventos uma tarefa

crítica para garantir a confiabilidade e a eficiência do sistema (Rodriguez *et al.*, 2020) (Sekar, Sendil kumar e Karthick, 2020).

Atualmente, os registradores digitais de perturbações (DFRs) e medidores de qualidade de energia geram volumes massivos de dados oscilográficos com alta resolução (Ukil e Zivanovic, 2014). No entanto, a transformação desses dados brutos em informações úteis ("conhecimento") representa um gargalo significativo para as concessionárias (Ukil e Zivanovic, 2014). A grande maioria desses registros não possui rótulos — ou seja, a causa e o tipo da perturbação são desconhecidos no momento da coleta — e o volume de dados é excessivo para ser processado manualmente por operadores humanos (Islam *et al.*, 2023). Além disso, a análise manual é um processo tedioso, impreciso e dependente da disponibilidade de especialistas, o que muitas vezes resulta em dados críticos sendo ignorados ou descartados (Shinde, Sonwane e Munje, 2019) (Mishra, Subudhi e Jain, 2019).

As abordagens tradicionais de processamento de sinais, como a Transformada de Fourier (FT) ou a Transformada Wavelet (WT) isolada, embora amplamente utilizadas, apresentam limitações quanto à extração de características em cenários ruidosos e dependem frequentemente de limiares fixos ou seleção manual de atributos (Mishra, Subudhi e Jain, 2019) (Sekar, Sendil kumar e Karthick, 2020). Diante da escassez de dados rotulados e da ausência de supervisão especializada constante, técnicas de Inteligência Artificial (IA), especificamente o Aprendizado de Máquina Não Supervisionado, emergem como soluções promissoras (Shinde, Sonwane e Munje, 2019) (Almasoudi, 2023) . Algoritmos de agrupamento (clustering), como o K-Means, permitem identificar automaticamente padrões ocultos e segregar eventos de qualidade de energia (como afundamentos, elevações e interrupções) sem a necessidade de treinamento prévio com rótulos [6] (Islam *et al.*, 2023).

Para aumentar a robustez dessa análise, a literatura recente propõe o uso de Deep Learning, como Autoencoders Convolucionais (CAE), para realizar a extração automática de características e a redução de dimensionalidade dos sinais antes do agrupamento (Rodriguez *et al.*, 2020) (Islam *et al.*, 2023). Essa abordagem híbrida elimina a necessidade de engenharia manual de características e melhora a imunidade a ruídos, permitindo que o sistema filtre anomalias e eventos de interesse de forma autônoma (Mishra, Subudhi e Jain, 2019) (Islam *et al.*, 2023).

Neste contexto, este trabalho propõe a aplicação de técnicas de agrupamento e aprendizado profundo para a caracterização automática de perturbações elétricas, utilizando uma base de dados reais coletada nas subestações Sub3 e Sub8. O objetivo é demonstrar como algoritmos não supervisionados podem estruturar dados desconhecidos e auxiliar na tomada de decisão operacional, superando a barreira da falta de especialistas e contribuindo para a resiliência do sistema elétrico frente a falhas e eventos imprevistos (Almasoudi, 2023) (Diahovchenko e Keane, 2025).

2. Fundamentação teórica

Esta seção apresenta os conceitos fundamentais sobre a Qualidade de Energia (PQ), bem como as técnicas de Inteligência Artificial adotadas para o processamento de grandes volumes de dados não rotulados: o algoritmo K-Means e os Autoencoders Convolucionais. A escolha dessas teorias justifica-se pela necessidade de automatizar a análise de perturbações em cenários onde a classificação manual é inviável.

2.1. Perturbações na Qualidade de Energia

A qualidade de energia refere-se à conformidade da forma de onda de tensão, corrente e frequência com padrões estabelecidos. Desvios nestes parâmetros são classificados como fenômenos eletromagnéticos. De acordo com a revisão de 2019 da norma IEEE Std 1159, esses fenômenos são categorizados com base em seu conteúdo espectral e duração, alinhando-se aos conceitos de compatibilidade eletromagnética. As categorias principais utilizadas pela comunidade de qualidade de energia incluem: Transientes (Impulsivos e Oscilatórios), Variações de Curta Duração (que englobam os Afundamentos, também denominados Dips ou Sags, Elevações ou Swells, e Interrupções) e Distorção da Forma de Onda (incluindo Harmônicos e Ruído) (IEEE, 2019).

A análise desses eventos é crítica, pois perturbações podem causar falhas em equipamentos sensíveis, perdas econômicas e instabilidade na rede. No entanto, a modernização das redes (Smart Grids) resultou em um aumento exponencial no volume de dados registrados por medidores digitais, criando um cenário de *Big Data* onde a maioria dos registros não possui rótulos e a análise manual por especialistas tornou-se impraticável (Ukil e Zivanovic, 2014), (Islam *et al.*, 2023).

2.2. Aprendizado de Máquina Não Supervisionado: K-Means

Para lidar com a ausência de dados rotulados, a literatura aponta o uso de aprendizado não supervisionado. O algoritmo de clusterização K-Means é uma das técnicas mais consolidadas para agrupar dados com base em similaridade de características, sem a necessidade de supervisão humana prévia (Shinde, Sonwane e Munje, 2019).

O objetivo do K-Means é particionar um conjunto de dados em k grupos (clusters), minimizando a soma das distâncias quadráticas entre cada ponto de dados e o centroide do seu cluster (média dos pontos) (Teeuwsen, 2005). O algoritmo opera iterativamente:

1. Inicializa arbitrariamente k centroides.
2. Atribui cada amostra ao centroide mais próximo (geralmente usando a Distância Euclidiana).
3. Recalcula os centroides com base na média das amostras atribuídas.
4. Repete o processo até a convergência (Shinde, Sonwane e Munje, 2019), (Teeuwsen, 2005).

A validação da qualidade dos clusters em cenários não supervisionados é frequentemente realizada por métricas como a pontuação de silhueta (Silhouette Score) ou o método do cotovelo (Elbow Method), que avaliam a coesão interna e a separação entre os grupos (Islam *et al.*, 2023).

2.3. Deep Learning e Autoencoders Convolucionais

Embora o K-Means seja eficaz, seu desempenho diminui quando aplicado diretamente a dados de alta dimensão, como formas de onda brutas de tensão. Para mitigar isso, utiliza-se a técnica de Deep Learning conhecida como Autoencoder (AE) para redução de dimensionalidade e extração de características (Islam *et al.*, 2023), (Rodriguez *et al.*, 2020).

Um Autoencoder é uma rede neural treinada para copiar sua entrada para sua saída. Ele consiste em duas partes:

- Codificador (Encoder): Comprime os dados de entrada em uma representação latente de menor dimensão (espaço de características), capturando os atributos mais salientes do sinal.
- Decodificador (Decoder): Reconstrói o sinal original a partir dessa representação latente, minimizando o erro de reconstrução (Islam *et al.*, 2023), (Rodriguez *et al.*, 2020).

Ao utilizar camadas convolucionais (CAE - Convolutional Autoencoder), o modelo torna-se capaz de filtrar ruídos e extrair padrões temporais complexos das perturbações elétricas melhor do que a extração manual de características (Almasoudi, 2023), (Islam *et al.*, 2023). A combinação do CAE para extração de atributos com o K-Means para agrupamento é uma abordagem robusta para classificar dados de perturbações reais e ruidosos (Islam *et al.*, 2023).

Trabalhos relacionados

A aplicação de técnicas de Inteligência Artificial para a análise de Qualidade de Energia (PQ) tem sido amplamente explorada na literatura recente, com abordagens que variam desde sistemas especialistas baseados em regras até redes neurais profundas. Foi conduzida uma revisão da literatura focada em métodos de detecção e classificação de perturbações, permitindo situar a presente proposta frente ao estado da arte.

(Mishra, Subudhi e Jain, 2019) propuseram um modelo baseado em Redes Neurais Convolucionais (CNN) para classificar 16 tipos de perturbações de energia, incluindo eventos simples e complexos. O estudo utilizou a Transformada Wavelet Contínua (CWT) para converter sinais unidimensionais em representações de imagem, que serviram de entrada para a CNN. Embora o modelo tenha demonstrado alta imunidade a ruídos e precisão superior a métodos tradicionais, a abordagem foi supervisionada, dependendo de um vasto conjunto de dados sintéticos rotulados para o treinamento, o que nem sempre reflete a realidade de dados de campo não rotulados.

Em uma linha semelhante, (Rodriguez *et al.*, 2020) desenvolveram uma abordagem híbrida utilizando Autoencoders Convolucionais (CAE) para redução de dimensionalidade, seguidos por Redes Neurais Recorrentes (RNN) do tipo Long Short-Term Memory (LSTM) empilhadas para a classificação. O estudo destacou a capacidade dos CAEs em comprimir o tamanho do sinal mantendo características dinâmicas relevantes, o que reduziu significativamente o tempo de processamento. Contudo, assim como em (Rodriguez *et al.*, 2020), a validação foi realizada majoritariamente com dados sintéticos gerados a partir de modelos matemáticos parametrizados, mantendo a dependência de rótulos prévios para a etapa de classificação.

Abordando a questão da falta de rótulos, (Shinde, Sonwane e Munje, 2019) exploraram o uso de aprendizado de máquina não supervisionado, especificamente o algoritmo K-Means, para agrupar eventos de afundamento, elevação e interrupção. O trabalho demonstrou a viabilidade de agrupar amostras semelhantes sem treinamento supervisionado prévio. No entanto, a extração de características baseou-se em atributos tradicionais, que podem não capturar a complexidade de perturbações não lineares ou transitórios de alta frequência presentes em redes modernas.

Mais recentemente, (Islam *et al.*, 2023) apresentaram uma técnica não supervisionada que combina Deep Learning e clusterização, utilizando CAEs para extração automática de características e K-Means para o agrupamento. O estudo inovou

ao aplicar o método em dados de campo reais de uma rede de distribuição, utilizando a visualização t-SNE para interpretar os clusters. A principal contribuição dessa abordagem foi a capacidade de filtrar formas de onda anômalas de eventos recorrentes sem a necessidade de rotulagem massiva.

Com base nesses estudos, verifica-se que, embora o uso de Deep Learning (Mishra, Subudhi e Jain, 2019), (Rodriguez *et al.*, 2020) e técnicas de clusterização (Shinde, Sonwane e Munje, 2019) estejam bem estabelecidos, existe uma lacuna na aplicação de métodos puramente não supervisionados para a caracterização exploratória de grandes bases de dados reais e desconhecidas, onde não há especialistas para validar classes ou criar rótulos iniciais. O presente trabalho se diferencia ao aplicar a arquitetura de CAE e K-Means similar a (Islam *et al.*, 2023) especificamente no contexto dos dados das subestações, visando validar a robustez da metodologia na descoberta de padrões intrínsecos em um novo conjunto de dados reais que carece de qualquer curadoria prévia.

4. Solução computacional

Este capítulo detalha a arquitetura da solução proposta, as ferramentas tecnológicas selecionadas e o pipeline de processamento de dados desenvolvido para a caracterização não supervisionada de perturbações elétricas. A metodologia computacional foi estruturada para operar em ambiente de nuvem, visando escalabilidade e reprodutibilidade.

4.1. Arquitetura da Solução

A solução foi projetada como um pipeline sequencial de aprendizado de máquina, dividido em três módulos principais: (i) Pré-processamento e Normalização; (ii) Extração de Características via Deep Learning; e (iii) Agrupamento e Análise. A arquitetura proposta busca transformar dados brutos de oscilografia em clusters de eventos significativos sem a necessidade de intervenção humana para rotulagem prévia.

O fluxo de dados inicia-se com a ingestão das séries temporais brutas provenientes das subestações transmissão de energia. Em seguida, uma Rede Neural do tipo Autoencoder Convolucional (CAE) é utilizada para comprimir esses sinais em um vetor de características latentes (latent space), reduzindo a dimensionalidade e filtrando ruídos. Por fim, o algoritmo K-Means é aplicado sobre esse espaço latente para segregar os eventos, conforme validado por (Islam *et al.*, 2023) em cenários de Big Data de redes de distribuição.

4.2. Ambiente de Desenvolvimento e Tecnologias

Para a implementação da solução, optou-se pela linguagem de programação Python (versão 3.8 ou superior), devido ao seu vasto ecossistema de bibliotecas voltadas para Ciência de Dados e Inteligência Artificial. O ambiente de desenvolvimento escolhido foi o Google Colab, uma plataforma baseada em nuvem que oferece acesso gratuito a Unidades de Processamento Gráfico (GPUs), essenciais para acelerar o treinamento das redes neurais profundas propostas neste trabalho.

As principais bibliotecas utilizadas na construção da solução incluem:

• Pandas e NumPy: Para manipulação estruturada de dados matriciais e operações de álgebra linear necessárias no tratamento das oscilografias.

• TensorFlow e Keras: Frameworks de alto nível utilizados para a construção, treinamento e validação da arquitetura do Autoencoder Convolucional.

• Scikit-learn: Utilizada para a implementação do algoritmo K-Means, normalização de dados (StandardScaler) e cálculo de métricas de validação como o Silhouette Score.

• Matplotlib e Seaborn: Para a visualização dos sinais elétricos, curvas de perda (loss) durante o treinamento e projeção gráfica dos clusters formados.

4.3. Pipeline de Processamento e Modelagem

O desenvolvimento da solução computacional segue um fluxo rigoroso de etapas, descritas a seguir.

4.3.1. Coleta e Pré-processamento dos Dados

Os dados brutos, consistindo em formas de onda de tensão trifásica, são submetidos a uma etapa de limpeza para remoção de registros corrompidos ou com janelas de tempo inconsistentes. Dado que redes neurais são sensíveis à escala dos dados de entrada, aplica-se a técnica de normalização Z-score (ou padronização). Conforme recomendado por Teeuwsen (2005) e Lim et al. (2018), cada sinal é ajustado para possuir média zero e desvio padrão unitário. Isso garante que a rede neural aprenda padrões baseados na forma da onda (morfologia do distúrbio) e não na magnitude absoluta da tensão, o que é crucial para diferenciar afundamentos de interrupções, por exemplo.

4.3.2. Extração de Características com Autoencoder Convolucional (CAE)

A extração de características é realizada por uma rede neural profunda não supervisionada. A arquitetura implementada é um Autoencoder Convolucional, composto por:

• Encoder: Sequência de camadas Conv1D (convolução unidimensional) seguidas por camadas de MaxPooling. Esta etapa reduz a dimensionalidade do sinal de entrada, forçando o modelo a reter apenas as informações mais relevantes no vetor latente (camada de gargalo ou bottleneck).

• Decoder: Sequência de camadas Conv1D e UpSampling, que tentam reconstruir o sinal original a partir do vetor latente.

O modelo é compilado utilizando o otimizador Adam, conhecido por sua eficiência em problemas com grandes volumes de dados e parâmetros ruidosos (Rodriguez et al., 2020). A função de perda (loss function) adotada é o Erro Quadrático Médio (MSE), visando minimizar a diferença entre o sinal de entrada e o sinal reconstruído.

4.3.3. Clusterização e Visualização

Após o treinamento do CAE, a parte do Decoder é descartada, e o Encoder é utilizado para gerar os vetores de características reduzidos de toda a base de dados. Esses vetores servem de entrada para o algoritmo K-Means.

Para determinar o número ótimo de clusters (k), implementa-se o método do cotovelo (Elbow Method) analisando a inércia (soma dos erros quadráticos intra-cluster) e o coeficiente de Silhueta. Para a interpretação visual dos resultados, utiliza-se a técnica t-SNE (t-Distributed Stochastic Neighbor Embedding), que projeta os vetores de alta dimensão em um plano 2D ou 3D, permitindo a verificação visual da separabilidade das classes de perturbações (sags, swells, harmônicos, etc.), conforme metodologia aplicada por (Islam *et al.*, 2023).

5. Avaliação experimental

Esta seção detalha o planejamento dos experimentos computacionais desenhados para validar a metodologia proposta, bem como os resultados esperados a partir do processamento da base de dados das subestações Sub3 e Sub8.

5.1. Planejamento da pesquisa

A avaliação experimental será conduzida em um ambiente computacional utilizando a linguagem Python, com suporte das bibliotecas TensorFlow/Keras para a construção das redes neurais e Scikit-learn para os algoritmos de agrupamento. O fluxo de trabalho experimental está dividido em três etapas principais:

1. Pré-processamento dos Dados: A base de dados bruta, contendo oscilografias de tensão das subestações Sub3 e Sub8, será submetida a uma etapa de limpeza e normalização. Será aplicada a normalização z-score para garantir que os sinais possuam média zero e variância unitária, facilitando a convergência do treinamento da rede neural. Os sinais serão redimensionados para um tamanho fixo de amostras, garantindo uniformidade na entrada do modelo.
2. Treinamento do Autoencoder Convolucional (CAE): Será implementada e treinada uma arquitetura de CAE composta por camadas de convolução e pooling (codificador) e camadas de deconvolução e upsampling (decodificador). O modelo será treinado de forma não supervisionada para minimizar o Erro Quadrático Médio (MSE) entre a entrada original e a saída reconstruída. O vetor de características latentes (camada de bottleneck) será extraído para representar cada sinal em baixa dimensão,.
3. Agrupamento e Validação: O algoritmo K-Means será aplicado aos vetores de características extraídos. Para determinar o número ideal de clusters (k), será utilizado o Método do Cotovelo (Elbow Method), analisando a soma dos erros quadráticos intra-cluster (WSS). A qualidade dos agrupamentos formados será avaliada por meio da métrica de Pontuação de Silhueta (Silhouette Score), que mede a coesão e a separação dos grupos. Adicionalmente, técnicas de redução de dimensionalidade, como t-SNE, serão empregadas para visualização 2D ou 3D da separação dos dados.

5.2. Resultados Esperados

Espera-se que a aplicação da metodologia proposta resulte na segregação automática e coerente dos registros de perturbações das subestações. Os resultados devem demonstrar:

- A capacidade do CAE em reconstruir os sinais de tensão com baixo erro de reconstrução (RMSE e MAPE), comprovando que as características essenciais das perturbações foram preservadas no espaço latente.

- A formação de clusters distintos que correspondam a classes físicas de eventos, como afundamentos de tensão (sags), elevações (swells), interrupções e operação normal, sem a necessidade de rótulos prévios.
- Uma pontuação de silhueta próxima de 1 para os grupos formados, indicando alta coesão interna e boa separação entre tipos de eventos distintos.
- A identificação de anomalias ou padrões atípicos que se distanciem dos centroides dos clusters principais, permitindo uma triagem eficiente de eventos raros para análise posterior.

Ao final, busca-se confirmar que a abordagem não supervisionada é uma ferramenta viável para auxiliar a operação das subestações na gestão de grandes volumes de dados de qualidade de energia.

6. Cronograma

A execução deste projeto foi planejada para ocorrer entre 15 de dezembro de 2025 e 10 abril de 2026. As atividades foram distribuídas de forma lógica para garantir o cumprimento dos objetivos dentro do prazo estipulado, conforme detalhado no **Quadro 1**.

Quadro 1 – Cronograma de Atividades

Fases / Atividades	**Dez/ 2025**	**Jan/ 2026**	**Fev/ 2026**	**Mar/ 2026**	**Abr/ 2026**
1. Definição e Refinamento	**X**				
1.1 Definição final do tema	X				
1.2 Refinamento da proposta e objetivos	X				
2. Revisão e Desenvolvimento		**X**	**X**		
2.1 Revisão bibliográfica sistemática		X			
2.2 Projeto de TCC		X			
2.3 Pré-processamento da base de dados		X			
2.4 Implementação e treinamento do CAE			X		
3. Testes e Análise			**X**	**X**	
3.1 Aplicação do K-Means e métricas de validação			X		
3.2 Análise dos clusters e visualização (t-SNE)				X	
4. Finalização				**X**	**X**
4.1 Escrita dos capítulos de resultados e discussão				X	
4.2 Revisão final do texto e formatação					X
4.3 Entrega e Apresentação Final					X

Justificativa das Fases:

• **Fase 1 (Dezembro):** Dedicada ao alinhamento final do escopo com o orientador para evitar desvios durante a execução.

• **Fase 2 (Janeiro/Fevereiro):** Concentra o esforço técnico mais pesado. O pré-processamento e o treinamento do Autoencoder exigem tempo para ajuste de hiperparâmetros, justificando a alocação de dois meses.

• **Fase 3 (Fevereiro/Março):** Com as características extraídas, a fase de testes foca na clusterização e na interpretação qualitativa dos resultados, essencial para a validação do estudo.

• **Fase 4 (Março/Abril):** A redação final ocorre em paralelo com a análise dos últimos resultados para garantir a consistência do texto, culminando na defesa em abril.

7. Referências

ALMASOUDI, F. M. Enhancing Power Grid Resilience through Real-Time Fault Detection and Remediation Using Advanced Hybrid Machine Learning Models. **Sustainability**, 2023. 15.

DIAHOVCHENKO, I.; KEANE, A. Clustering for power system stability using graph theory and electrical distance. **Sustainable Energy, Grids and Networks**, 2025. 43.

IEEE. IEEE Recommended Practice for Monitoring Electric Power Quality. **IEEE Std 1159-2019 (Revision of IEEE Std 1159-2009)**, 2019. 1-98.

ISLAM, M. M. *et al.* Unsupervised clustering of disturbances in power systems via deep convolutional autoencoders. **IEEE**, 2023.

MISHRA, P. K.; SUBUDHI, U.; JAIN, S. Power Quality Disturbances Classification with Deep Learning Approach. **2019 International Conference on Smart Energy Systems and Technologies (SEST)**, 2019.

RODRIGUEZ, M. A. *et al.* Power Quality Disturbance Classification via Deep Convolutional Auto-Encoders and Stacked LSTM Recurrent Neural Networks. **IEEE**, 2020.

SEKAR, K.; SENDIL KUMAR, S.; KARTHICK, K. Power Quality Disturbance Detection using Machine Learning Algorithm. **IEEE**, 2020.

SHINDE, P.; SONWANE, P.; MUNJE, R. Machine Learning based Clustering for Identifying Power Quality Events, 2019.

TEEUWSEN, S. P. **Oscillatory Stability Assessment of Power Systems using Computational Intelligence**. 2005., 2005.

UKIL, A.; ZIVANOVIC, R. Automated Analysis of Power Systems Disturbance Records: Smart Grid Big Data Perspective. **2014 IEEE Innovative Smart Grid Technologies - Asia (ISGT ASIA)**, 2014.