UFRR
UNIVERSIDADE FEDERAL DE RORAIMA
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO
ESPECIALIZAÇÃO EM COMPUTAÇÃO APLICADA NA INDÚSTRIA 4.0

RAFAEL BENZAQUEM NETO

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de Clustering e Deep Learning.

Boa Vista – Roraima,
Janeiro de 2026

RAFAEL BENZAQUEM NETO

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de Clustering e Deep Learning.

Monografia de Pós-graduação *Lato Sensu* apresentada à Especialização em Computação Aplicada na Indústria 4.0 da Universidade Federal de Roraima, como requisito parcial para a obtenção do grau de especialista em computação aplicada na indústria 4.0.

Boa Vista – Roraima,
Janeiro de 2026

Sumário

1. Introdução 1
2. Fundamentação teórica 2
   2.1. Perturbações na Qualidade de Energia 3
   2.2. Aprendizado de Máquina Não Supervisionado: K-Means 3
   2.3. Deep Learning e Autoencoders Convolucionais 3
4. Solução computacional 5
   4.1. Arquitetura da Solução 5
   4.2. Ambiente de Desenvolvimento e Tecnologias 5
   4.3. Pipeline de Processamento e Modelagem 6
      4.3.1. Coleta e Pré-processamento dos Dados 6
      4.3.2. Extração de Características com Autoencoder Convolucional (CAE) 6
      4.3.3. Clusterização e Visualização 7
5. Resultados e Discussão 7
   5.1. Execução do Pipeline Computacional 7
   5.2 Resultados Obtidos e Curadoria Semântica 9
6. Considerações Finais 9
7. Referências 10

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de Clustering e Deep Learning.

Rafael Benzaquem Neto[1], Josiane do Couto Rodrigues [1]

[1]Departamento de Ciência da Computação – Universidade Federal de Roraima (UFRR) – Boa Vista – RR – Brasil

rafaelbenzaquem@ulbra.edu.br, josiane.rodrigues@ufrr.br

Resumo. *A modernização das redes elétricas gera volumes massivos de dados de perturbações não rotulados, tornando a análise manual inviável. Este estudo objetiva caracterizar automaticamente esses eventos em subestações de distribuição utilizando dados reais sem supervisão humana. A solução computacional integra Deep Learning via Autoencoders Convolucionais para extração de características e o algoritmo K-Means para o agrupamento dos sinais. A pesquisa processará oscilografias das subestações Sub3 e Sub8, abrangendo normalização, treinamento da rede neural e validação dos grupos formados via métricas de silhueta. Espera-se demonstrar a viabilidade da segregação autônoma de eventos como afundamentos e elevações, filtrando anomalias críticas para auxiliar a tomada de decisão. O trabalho contribui para a resiliência do sistema elétrico ao superar o gargalo da rotulagem manual em cenários de Big Data.*

Abstract. *The modernization of electrical grids generates massive volumes of unlabeled disturbance data, making manual analysis unfeasible. This study aims to automatically characterize these events in distribution substations using real data without human supervision. The computational solution integrates Deep Learning via Convolutional Autoencoders for feature extraction and the K-Means algorithm for signal clustering. The research will process oscillography from substations Sub3 and Sub8, covering normalization, neural network training, and validation of formed groups via silhouette metrics. It is expected to demonstrate the feasibility of autonomous segregation of events such as sags and swells, filtering critical anomalies to aid decision-making. The work contributes to power system resilience by overcoming the manual labeling bottleneck in Big Data scenarios.*

1. Introdução

A modernização dos sistemas de energia elétrica e a transição contínua para o conceito de *Smart Grids* resultaram em uma integração massiva de dispositivos eletrônicos inteligentes, fontes de energia renovável e sistemas de monitoramento avançado (Ukil e Zivanovic, 2014) (Mishra, Subudhi e Jain, 2019). Embora essa evolução tecnológica ofereça maior observabilidade da rede, ela também introduziu novos desafios, particularmente no que tange à Qualidade de Energia (PQ). A proliferação de cargas não lineares e a intermitência de fontes renováveis aumentaram a complexidade das perturbações elétricas, tornando a detecção e classificação desses eventos uma tarefa

crítica para garantir a confiabilidade e a eficiência do sistema (Rodriguez *et al.*, 2020) (Sekar, Sendil kumar e Karthick, 2020).

Atualmente, os registradores digitais de perturbações (DFRs) e medidores de qualidade de energia geram volumes massivos de dados oscilográficos com alta resolução (Ukil e Zivanovic, 2014). No entanto, a transformação desses dados brutos em informações úteis ("conhecimento") representa um gargalo significativo para as concessionárias (Ukil e Zivanovic, 2014). A grande maioria desses registros não possui rótulos — ou seja, a causa e o tipo da perturbação são desconhecidos no momento da coleta — e o volume de dados é excessivo para ser processado manualmente por operadores humanos (Islam *et al.*, 2023). Além disso, a análise manual é um processo tedioso, impreciso e dependente da disponibilidade de especialistas, o que muitas vezes resulta em dados críticos sendo ignorados ou descartados (Shinde, Sonwane e Munje, 2019) (Mishra, Subudhi e Jain, 2019).

As abordagens tradicionais de processamento de sinais, como a Transformada de Fourier (FT) ou a Transformada Wavelet (WT) isolada, embora amplamente utilizadas, apresentam limitações quanto à extração de características em cenários ruidosos e dependem frequentemente de limiares fixos ou seleção manual de atributos (Mishra, Subudhi e Jain, 2019) (Sekar, Sendil kumar e Karthick, 2020). Diante da escassez de dados rotulados e da ausência de supervisão especializada constante, técnicas de Inteligência Artificial (IA), especificamente o Aprendizado de Máquina Não Supervisionado, emergem como soluções promissoras (Shinde, Sonwane e Munje, 2019) (Almasoudi, 2023) . Algoritmos de agrupamento (clustering), como o K-Means, permitem identificar automaticamente padrões ocultos e segregar eventos de qualidade de energia (como afundamentos, elevações e interrupções) sem a necessidade de treinamento prévio com rótulos [6] (Islam *et al.*, 2023).

Para aumentar a robustez dessa análise, a literatura recente propõe o uso de Deep Learning, como Autoencoders Convolucionais (CAE), para realizar a extração automática de características e a redução de dimensionalidade dos sinais antes do agrupamento (Rodriguez *et al.*, 2020) (Islam *et al.*, 2023). Essa abordagem híbrida elimina a necessidade de engenharia manual de características e melhora a imunidade a ruídos, permitindo que o sistema filtre anomalias e eventos de interesse de forma autônoma (Mishra, Subudhi e Jain, 2019) (Islam *et al.*, 2023).

Neste contexto, este trabalho propõe a aplicação de técnicas de agrupamento e aprendizado profundo para a caracterização automática de perturbações elétricas, utilizando uma base de dados reais coletada nas subestações Sub3 e Sub8. O objetivo é demonstrar como algoritmos não supervisionados podem estruturar dados desconhecidos e auxiliar na tomada de decisão operacional, superando a barreira da falta de especialistas e contribuindo para a resiliência do sistema elétrico frente a falhas e eventos imprevistos (Almasoudi, 2023) (Diahovchenko e Keane, 2025).

2. Fundamentação teórica

Esta seção apresenta os conceitos fundamentais sobre a Qualidade de Energia (PQ), bem como as técnicas de Inteligência Artificial adotadas para o processamento de grandes volumes de dados não rotulados: o algoritmo K-Means e os Autoencoders Convolucionais. A escolha dessas teorias justifica-se pela necessidade de automatizar a análise de perturbações em cenários onde a classificação manual é inviável.

2.1. Perturbações na Qualidade de Energia

A qualidade de energia refere-se à conformidade da forma de onda de tensão, corrente e frequência com padrões estabelecidos. Desvios nestes parâmetros são classificados como fenômenos eletromagnéticos. De acordo com a revisão de 2019 da norma IEEE Std 1159, esses fenômenos são categorizados com base em seu conteúdo espectral e duração, alinhando-se aos conceitos de compatibilidade eletromagnética. As categorias principais utilizadas pela comunidade de qualidade de energia incluem: Transientes (Impulsivos e Oscilatórios), Variações de Curta Duração (que englobam os Afundamentos, também denominados Dips ou Sags, Elevações ou Swells, e Interrupções) e Distorção da Forma de Onda (incluindo Harmônicos e Ruído) (IEEE, 2019).

A análise desses eventos é crítica, pois perturbações podem causar falhas em equipamentos sensíveis, perdas econômicas e instabilidade na rede. No entanto, a modernização das redes (Smart Grids) resultou em um aumento exponencial no volume de dados registrados por medidores digitais, criando um cenário de *Big Data* onde a maioria dos registros não possui rótulos e a análise manual por especialistas tornou-se impraticável (Ukil e Zivanovic, 2014), (Islam *et al.*, 2023).

2.2. Aprendizado de Máquina Não Supervisionado: K-Means

Para lidar com a ausência de dados rotulados, a literatura aponta o uso de aprendizado não supervisionado. O algoritmo de clusterização K-Means é uma das técnicas mais consolidadas para agrupar dados com base em similaridade de características, sem a necessidade de supervisão humana prévia (Shinde, Sonwane e Munje, 2019).

O objetivo do K-Means é particionar um conjunto de dados em k grupos (clusters), minimizando a soma das distâncias quadráticas entre cada ponto de dados e o centroide do seu cluster (média dos pontos) (Teeuwsen, 2005). O algoritmo opera iterativamente:

1. Inicializa arbitrariamente k centroides.
2. Atribui cada amostra ao centroide mais próximo (geralmente usando a Distância Euclidiana).
3. Recalcula os centroides com base na média das amostras atribuídas.
4. Repete o processo até a convergência (Shinde, Sonwane e Munje, 2019), (Teeuwsen, 2005).

A validação da qualidade dos clusters em cenários não supervisionados é frequentemente realizada por métricas como a pontuação de silhueta (Silhouette Score) ou o método do cotovelo (Elbow Method), que avaliam a coesão interna e a separação entre os grupos (Islam *et al.*, 2023).

2.3. Deep Learning e Autoencoders Convolucionais

Embora o K-Means seja eficaz, seu desempenho diminui quando aplicado diretamente a dados de alta dimensão, como formas de onda brutas de tensão. Para mitigar isso, utiliza-se a técnica de Deep Learning conhecida como Autoencoder (AE) para redução de dimensionalidade e extração de características (Islam *et al.*, 2023), (Rodriguez *et al.*, 2020).

Um Autoencoder é uma rede neural treinada para copiar sua entrada para sua saída. Ele consiste em duas partes:

- Codificador (Encoder): Comprime os dados de entrada em uma representação latente de menor dimensão (espaço de características), capturando os atributos mais salientes do sinal.
- Decodificador (Decoder): Reconstrói o sinal original a partir dessa representação latente, minimizando o erro de reconstrução (Islam *et al.*, 2023), (Rodriguez *et al.*, 2020).

Ao utilizar camadas convolucionais (CAE - Convolutional Autoencoder), o modelo torna-se capaz de filtrar ruídos e extrair padrões temporais complexos das perturbações elétricas melhor do que a extração manual de características (Almasoudi, 2023), (Islam *et al.*, 2023). A combinação do CAE para extração de atributos com o K-Means para agrupamento é uma abordagem robusta para classificar dados de perturbações reais e ruidosos (Islam *et al.*, 2023).

Trabalhos relacionados

A aplicação de técnicas de Inteligência Artificial para a análise de Qualidade de Energia (PQ) tem sido amplamente explorada na literatura recente, com abordagens que variam desde sistemas especialistas baseados em regras até redes neurais profundas. Foi conduzida uma revisão da literatura focada em métodos de detecção e classificação de perturbações, permitindo situar a presente proposta frente ao estado da arte.

(Mishra, Subudhi e Jain, 2019) propuseram um modelo baseado em Redes Neurais Convolucionais (CNN) para classificar 16 tipos de perturbações de energia, incluindo eventos simples e complexos. O estudo utilizou a Transformada Wavelet Contínua (CWT) para converter sinais unidimensionais em representações de imagem, que serviram de entrada para a CNN. Embora o modelo tenha demonstrado alta imunidade a ruídos e precisão superior a métodos tradicionais, a abordagem foi supervisionada, dependendo de um vasto conjunto de dados sintéticos rotulados para o treinamento, o que nem sempre reflete a realidade de dados de campo não rotulados.

Em uma linha semelhante, (Rodriguez *et al.*, 2020) desenvolveram uma abordagem híbrida utilizando Autoencoders Convolucionais (CAE) para redução de dimensionalidade, seguidos por Redes Neurais Recorrentes (RNN) do tipo Long Short-Term Memory (LSTM) empilhadas para a classificação. O estudo destacou a capacidade dos CAEs em comprimir o tamanho do sinal mantendo características dinâmicas relevantes, o que reduziu significativamente o tempo de processamento. Contudo, assim como em (Rodriguez *et al.*, 2020), a validação foi realizada majoritariamente com dados sintéticos gerados a partir de modelos matemáticos parametrizados, mantendo a dependência de rótulos prévios para a etapa de classificação.

Abordando a questão da falta de rótulos, (Shinde, Sonwane e Munje, 2019) exploraram o uso de aprendizado de máquina não supervisionado, especificamente o algoritmo K-Means, para agrupar eventos de afundamento, elevação e interrupção. O trabalho demonstrou a viabilidade de agrupar amostras semelhantes sem treinamento supervisionado prévio. No entanto, a extração de características baseou-se em atributos tradicionais, que podem não capturar a complexidade de perturbações não lineares ou transitórios de alta frequência presentes em redes modernas.

Mais recentemente, (Islam *et al.*, 2023) apresentaram uma técnica não supervisionada que combina Deep Learning e clusterização, utilizando CAEs para extração automática de características e K-Means para o agrupamento. O estudo inovou

ao aplicar o método em dados de campo reais de uma rede de distribuição, utilizando a visualização t-SNE para interpretar os clusters. A principal contribuição dessa abordagem foi a capacidade de filtrar formas de onda anômalas de eventos recorrentes sem a necessidade de rotulagem massiva.

Com base nesses estudos, verifica-se que, embora o uso de Deep Learning (Mishra, Subudhi e Jain, 2019), (Rodriguez *et al.*, 2020) e técnicas de clusterização (Shinde, Sonwane e Munje, 2019) estejam bem estabelecidos, existe uma lacuna na aplicação de métodos puramente não supervisionados para a caracterização exploratória de grandes bases de dados reais e desconhecidas, onde não há especialistas para validar classes ou criar rótulos iniciais. O presente trabalho se diferencia ao aplicar a arquitetura de CAE e K-Means similar a (Islam *et al.*, 2023) especificamente no contexto dos dados das subestações, visando validar a robustez da metodologia na descoberta de padrões intrínsecos em um novo conjunto de dados reais que carece de qualquer curadoria prévia.

4. Solução computacional

Este capítulo detalha a arquitetura da solução proposta, as ferramentas tecnológicas selecionadas e o pipeline de processamento de dados desenvolvido para a caracterização não supervisionada de perturbações elétricas. A metodologia computacional foi estruturada para operar em ambiente de nuvem, visando escalabilidade e reprodutibilidade.

4.1. Arquitetura da Solução

A solução foi projetada como um pipeline sequencial de aprendizado de máquina, dividido em três módulos principais: (i) Pré-processamento e Normalização; (ii) Extração de Características via Deep Learning; e (iii) Agrupamento e Análise. A arquitetura proposta busca transformar dados brutos de oscilografia em clusters de eventos significativos sem a necessidade de intervenção humana para rotulagem prévia.

O fluxo de dados inicia-se com a ingestão das séries temporais brutas provenientes das subestações transmissão de energia. Em seguida, uma Rede Neural do tipo Autoencoder Convolucional (CAE) é utilizada para comprimir esses sinais em um vetor de características latentes (latent space), reduzindo a dimensionalidade e filtrando ruídos. Por fim, o algoritmo K-Means é aplicado sobre esse espaço latente para segregar os eventos, conforme validado por (Islam *et al.*, 2023) em cenários de Big Data de redes de distribuição.

4.2. Ambiente de Desenvolvimento e Tecnologias

Para a implementação da solução, optou-se pela linguagem de programação Python (versão 3.8 ou superior), devido ao seu vasto ecossistema de bibliotecas voltadas para Ciência de Dados e Inteligência Artificial. O ambiente de desenvolvimento escolhido foi o Google Colab, uma plataforma baseada em nuvem que oferece acesso gratuito a Unidades de Processamento Gráfico (GPUs), essenciais para acelerar o treinamento das redes neurais profundas propostas neste trabalho.

As principais bibliotecas utilizadas na construção da solução incluem:

- **Pandas** e **NumPy**: Para manipulação estruturada de dados matriciais e operações de álgebra linear necessárias no tratamento das oscilografias.
- **TensorFlow** e **Keras**: Frameworks de alto nível utilizados para a construção, treinamento e validação da arquitetura do Autoencoder Convolucional.
- **Scikit-learn**: Utilizada para a implementação do algoritmo K-Means, normalização de dados (StandardScaler) e cálculo de métricas de validação como o Silhouette Score.
- **Matplotlib** e **Seaborn**: Para a visualização dos sinais elétricos, curvas de perda (loss) durante o treinamento e projeção gráfica dos clusters formados.

4.3. Pipeline de Processamento e Modelagem

O desenvolvimento da solução computacional segue um fluxo rigoroso de etapas, descritas a seguir.

4.3.1. Coleta e Pré-processamento dos Dados

Os dados brutos, consistindo em formas de onda de tensão trifásica, são submetidos a uma etapa de limpeza inicial para a remoção de registros corrompidos ou com janelas de tempo inconsistentes. Dado que as redes neurais e a etapa de classificação de distúrbios são altamente sensíveis à escala dos dados de entrada, os sinais de tensão serão normalizados com base em valores por unidade (p.u.), o que é realizado dividindo-se o valor instantâneo do sinal pelo valor de pico da tensão nominal do sistema (Islam *et al.*, 2023). Diferentemente da padronização Z-score aplicada individualmente — que forçaria os sinais a terem variância unitária e, consequentemente, eliminaria informações críticas de magnitude —, a conversão para p.u. alinha-se às práticas e definições da norma IEEE Std 1159:2019, preservando a magnitude real da tensão remanescente (retained voltage) (IEEE, 2019). Esse rigor é imprescindível para que o algoritmo de agrupamento consiga diferenciar corretamente os eventos baseados em suas amplitudes absolutas, como afundamentos de tensão ou sags (0,1 a 0,9 p.u.) em contraposição a interrupções (< 0,1 p.u.) (IEEE, 2019).

Adicionalmente, os registros oscilográficos, idealmente extraídos no formato padrão COMTRADE (Ukil e Zivanovic, 2014), serão redimensionados para assegurar a uniformidade exigida na entrada do modelo de Deep Learning. Com base nas diretrizes da IEEE Std 1159:2019, que define as variações RMS de curta duração como fenômenos ocorrendo em intervalos de 0,5 ciclo a 1 minuto (IEEE, 2019), e apoiando-se na metodologia validada por Islam et al. (2023), os sinais serão janelados em segmentos temporais padronizados, abrangendo, por exemplo, de 10 a 16 ciclos da frequência fundamental (IEEE, 2019). Eventos que ultrapassem essa duração poderão ser processados através de técnicas de janelamento deslizante (sliding window), garantindo a coerência temporal e a extração fidedigna das características morfológicas pela rede neural (Junior *et al.*, 2019).

4.3.2. Extração de Características com Autoencoder Convolucional (CAE)

A extração de características é realizada por uma rede neural profunda não supervisionada. A arquitetura implementada é um Autoencoder Convolucional, composto por:

- Encoder: Sequência de camadas Conv1D (convolução unidimensional) seguidas por camadas de MaxPooling. Esta etapa reduz a dimensionalidade do sinal de entrada, forçando o modelo a reter apenas as informações mais relevantes no vetor latente (camada de gargalo ou bottleneck).
- Decoder: Sequência de camadas Conv1D e UpSampling, que tentam reconstruir o sinal original a partir do vetor latente.

O modelo é compilado utilizando o otimizador Adam, conhecido por sua eficiência em problemas com grandes volumes de dados e parâmetros ruidosos (Rodriguez et al., 2020). A função de perda (loss function) adotada é o Erro Quadrático Médio (MSE), visando minimizar a diferença entre o sinal de entrada e o sinal reconstruído.

4.3.3. Clusterização e Visualização

Após o treinamento do CAE, a parte do Decoder é descartada, e o Encoder é utilizado para gerar os vetores de características reduzidos de toda a base de dados. Esses vetores servem de entrada para o algoritmo K-Means.

Para determinar o número ótimo de clusters (k), implementa-se o método do cotovelo (Elbow Method) analisando a inércia (soma dos erros quadráticos intra-cluster) e o coeficiente de Silhueta. Para a interpretação visual dos resultados, utiliza-se a técnica t-SNE (t-Distributed Stochastic Neighbor Embedding), que projeta os vetores de alta dimensão em um plano 2D ou 3D, permitindo a verificação visual da separabilidade das classes de perturbações (sags, swells, harmônicos, etc.), conforme metodologia aplicada por (Islam *et al.*, 2023).

5. Resultados e Discussão

Esta seção apresenta a avaliação experimental da metodologia proposta. A seção está dividida na descrição da execução do pipeline computacional estruturado para processar o volume de dados (Big Data) e na discussão dos resultados obtidos através da clusterização e da curadoria semântica baseada nas normativas de qualidade de energia.

5.1. Execução do Pipeline Computacional

A execução experimental foi conduzida em ambiente de nuvem (Google Colab), utilizando processamento acelerado por GPU para o treinamento da rede neural profunda. A pipeline (**Figura 1**) processou um total de 327 arquivos oscilográficos brutos no formato COMTRADE, originários das subestações de distribuição monitoradas nomeadas nesse trabalho como sub3 e sub8.

Figura 1 – Fluxograma da pipeline computacional

Na etapa de pré-processamento (Módulo 1), as formas de onda de tensão trifásica foram extraídas e normalizadas para valores por unidade (p.u.), dividindo-se as amostras pela tensão nominal de pico do sistema. Essa abordagem garantiu a preservação da magnitude física da tensão remanescente (retained voltage). Utilizando uma técnica de janelamento deslizante (sliding window), os sinais foram padronizados em tensores tridimensionais de 384 amostras (aproximadamente 16 ciclos), resultando em uma base de dados refinada com 12.092 eventos válidos para treinamento.

Para a extração de características (Módulo 2), o Autoencoder Convolucional (CAE) foi treinado de forma não supervisionada durante 100 épocas. O modelo demonstrou alta capacidade de compressão e retenção morfológica, reduzindo os sinais de entrada de alta dimensionalidade para um espaço latente de apenas 16 variáveis. O erro de reconstrução final (Root Mean Squared Error - RMSE) atingiu a marca de 0,00489 p.u. para a base completa, indicando que a arquitetura aprendeu com sucesso as assinaturas dinâmicas das perturbações, filtrando ruídos irrelevantes.

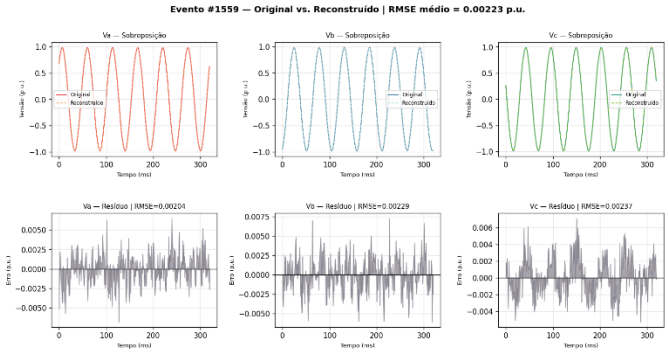

Figura 2 – Comparação entre a forma de onda original do distúrbio e o sinal reconstruído pelo Autoencoder Convolucional, demonstrando a preservação das características temporais essenciais.

Na etapa de agrupamento (Módulo 3), os vetores latentes foram padronizados via Z-score para adequação do cálculo de distâncias. A avaliação do número ótimo de agrupamentos (k) através do Método da Silhueta apontou k=6 como o particionamento matematicamente ideal (pontuação de 0,4907). Contudo, visando uma maior interpretabilidade operacional inicial, a clusterização K-Means foi executada com k=3, alcançando uma pontuação de silhueta de 0,4710. Esse valor atesta uma separação espacial satisfatória para dados de campo reais, que inerentemente possuem alto nível de ruído e eventos de fronteira.

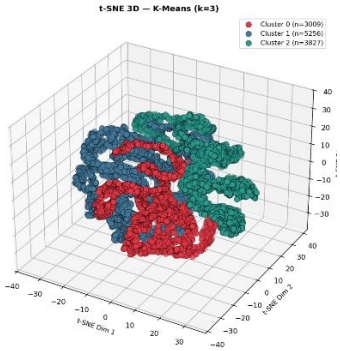

Figura 3 – Projeção de redução de dimensionalidade (t-SNE) ilustrando a separabilidade espacial dos 12.092 eventos no espaço latente em três agrupamentos principais.

5.2 Resultados Obtidos e Curadoria Semântica

A principal contribuição analítica desta avaliação consistiu na etapa de Curadoria Semântica Híbrida (Módulo 4). Em vez de atribuir rótulos baseados puramente nas médias matemáticas dos clusters, o algoritmo realizou um cruzamento individualizado de cada forma de onda com as diretrizes rigorosas da norma IEEE Std 1159:2019.

A análise autônoma do sistema revelou que a separação física global entre os três clusters principais (ΔVrms) era de apenas 0,0121 p.u., inferior ao limiar significativo de variabilidade (0,05 p.u.). Esse diagnóstico matemático evidenciou que a quase totalidade da base de dados (cerca de 90%) é dominada por um único tipo de fenômeno macro: os Afundamentos Moderados de Tensão (Sags), com tensões remanescentes variando na faixa de 0,56 a 0,57 p.u.

Dada essa homogeneidade, o K-Means subdividiu os eventos com base nas fases afetadas e pequenas assimetrias. O algoritmo de curadoria gerou automaticamente a seguinte distribuição semântica para o core dos dados:

- Sag Moderado — Fase B (pré-falta 0.68 p.u.): 3.444 eventos (28,5%).
- Sag Moderado — Fase A (pré-falta 0.68 p.u.): 2.708 eventos (22,4%).

A curadoria híbrida conseguiu identificar e resgatar 48 eventos de Interrupção (0,4% da base), que possuíam tensão inferior a 0,1 p.u. e estavam originalmente mascarados dentro dos grandes agrupamentos devido à sua baixa frequência de ocorrência.

Adicionalmente, ao calcular as distâncias espaciais dos eventos em relação aos seus centroides matemáticos, o algoritmo isolou 1.210 eventos atípicos (10,0% da base) classificados como "Anomalias para Inspeção Manual". Essa separação sugere valor prático da IA não supervisionada no setor elétrico: o sistema foi capaz de estruturar automaticamente 90% da base que possuía comportamento repetitivo e comum, permitindo que a equipe de engenharia da concessionária foque sua atenção exclusivamente nos 10% de anomalias críticas, resolvendo assim o gargalo operacional imposto pelo cenário de Big Data.

6. Considerações Finais

Este trabalho demonstrou a viabilidade técnica e o valor operacional da aplicação de técnicas de Inteligência Artificial não supervisionada para a caracterização autônoma de perturbações de qualidade de energia elétrica. O pipeline desenvolvido, integrando Deep Learning (Autoencoders Convolucionais) e clusterização (K-Means), foi capaz de processar uma base de dados reais de alta complexidade contendo 12.092 registros oscilográficos não rotulados.

A principal linha abordada por este estudo foi a dependência de especialistas humanos para a rotulagem de grandes volumes de dados. O Deep Learning atuou de forma autônoma na extração de características e redução de dimensionalidade estrutural, enquanto o módulo de inteligência baseada em regras conectou as descobertas matemáticas da IA aos limites físicos da norma IEEE Std 1159:2019. O diagnóstico final revelou uma rede de distribuição predominantemente afetada por afundamentos de tensão (*sags*) nas fases A e B, sinalizando anomalias sistêmicas.

A capacidade do sistema em atuar como um "filtro de triagem" pode viabilizar sua aplicabilidade para a indústria. Ao reclassificar minorias críticas (como interrupções de energia) e isolar 1.210 anomalias morfológicas, a ferramenta automatiza a etapa mais tediosa do monitoramento de *Smart Grids*, direcionando a expertise humana apenas para os eventos que de fato exigem investigação avançada.

Como perspectivas de trabalhos futuros, sugere-se a otimização da base de agrupamentos para hiperparâmetros de maior dimensionalidade (ex: k=6, conforme apontado pela validação por Silhueta do modelo), bem como a aplicação de algoritmos baseados em densidade, como o *DBSCAN*, visando lidar com perturbações multifatoriais e de fronteira.

7. Referências

ALMASOUDI, F. M. Enhancing Power Grid Resilience through Real-Time Fault Detection and Remediation Using Advanced Hybrid Machine Learning Models. **Sustainability**, 2023. 15.

DIAHOVCHENKO, I.; KEANE, A. Clustering for power system stability using graph theory and electrical distance. **Sustainable Energy, Grids and Networks**, 2025. 43.

IEEE. IEEE Recommended Practice for Monitoring Electric Power Quality. **IEEE Std 1159-2019 (Revision of IEEE Std 1159-2009)**, 2019. 1-98.

ISLAM, M. M. *et al.* Unsupervised clustering of disturbances in power systems via deep convolutional autoencoders. **IEEE**, 2023.

JUNIOR, W. L. Rodrigues *et al.* A Methodology for Detection of Power Quality Disturbances in the Context of Demand Side Management. **2019 4th International Conference on Smart and Sustainable Technologies (SpliTech)**, Split, 2019. 1-6.

MISHRA, P. K.; SUBUDHI, U.; JAIN, S. Power Quality Disturbances Classification with Deep Learning Approach. **2019 International Conference on Smart Energy Systems and Technologies (SEST)**, 2019.

RODRIGUEZ, M. A. *et al.* Power Quality Disturbance Classification via Deep Convolutional Auto-Encoders and Stacked LSTM Recurrent Neural Networks. **IEEE**, 2020.

SEKAR, K.; SENDIL KUMAR, S.; KARTHICK, K. Power Quality Disturbance Detection using Machine Learning Algorithm. **IEEE**, 2020.

SHINDE, P.; SONWANE, P.; MUNJE, R. Machine Learning based Clustering for Identifying Power Quality Events, 2019.

TEEUWSEN, S. P. **Oscillatory Stability Assessment of Power Systems using Computational Intelligence**. 2005., 2005.

UKIL, A.; ZIVANOVIC, R. Automated Analysis of Power Systems Disturbance Records: Smart Grid Big Data Perspective. **2014 IEEE Innovative Smart Grid Technologies - Asia (ISGT ASIA)**, 2014.