UFRR
UNIVERSIDADE FEDERAL DE RORAIMA
DEPARTAMENTO DE CIÊNCIA DA COMPUTAÇÃO
ESPECIALIZAÇÃO EM COMPUTAÇÃO APLICADA NA INDÚSTRIA 4.0

RAFAEL BENZAQUEM NETO

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de *Clustering* e *Deep Learning*.

Boa Vista – Roraima,
Abril de 2026

RAFAEL BENZAQUEM NETO

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de *Clustering* e *Deep Learning*.

Monografia de Pós-graduação *Lato Sensu* apresentada à Especialização em Computação Aplicada na Indústria 4.0 da Universidade Federal de Roraima, como requisito parcial para a obtenção do grau de especialista em computação aplicada na indústria 4.0.

Boa Vista – Roraima,
Abril de 2026

Sumário

1. Introdução 1
2. Fundamentação teórica 2
   2.1. Perturbações na Qualidade de Energia 3
   2.2. Aprendizado de Máquina Não Supervisionado: *K-Means* 3
   2.3. *Deep Learning* e *Autoencoders* Convolucionais 3
3. Trabalhos relacionados 4
4. Solução computacional 5
   4.1. Arquitetura da Solução 5
   4.2. Ambiente de Desenvolvimento e Tecnologias 5
   4.3. *Pipeline* de Processamento e Modelagem 5
      4.3.1. Coleta e Pré-processamento dos Dados 6
      4.3.2. Extração de Características com *Autoencoder* Convolucional (CAE) 6
      4.3.3. Clusterização e Visualização 6
5. Resultados e Discussão 7
   5.1. Execução do Pipeline Computacional 7
   5.2 Resultados Obtidos e Curadoria Semântica 9
6. Considerações Finais 9
7. Referências 10

Caracterização Não Supervisionada de Perturbações Elétricas em Subestações de Distribuição de Energia utilizando Técnicas de *Clustering* e *Deep Learning*.

Rafael Benzaquem Neto[1], Josiane do Couto Rodrigues [2]

[1]Departamento de Ciência da Computação – Universidade Federal de Roraima (UFRR) – Boa Vista – RR – Brasil

[2]Departamento de Engenharia Elétrica – Universidade Federal de Roraima (UFRR) – Boa Vista – RR – Brasil

rafaelbenzaquem@ulbra.edu.br, josiane.rodrigues@ufrr.br

Resumo. *A modernização das redes elétricas gera volumes massivos de dados de perturbações não rotulados, tornando a análise manual inviável. Este estudo objetiva caracterizar automaticamente esses eventos em subestações de distribuição utilizando dados reais sem supervisão humana. A solução computacional integra Deep Learning via Autoencoders Convolucionais para extração de características e o algoritmo K-Means para o agrupamento dos sinais. A pesquisa processará oscilografias das subestações Sub3 e Sub8, abrangendo normalização, treinamento da rede neural e validação dos grupos formados via métricas de silhueta. Espera-se demonstrar a viabilidade da segregação autônoma de eventos como afundamentos e elevações, filtrando anomalias críticas para auxiliar a tomada de decisão. O trabalho contribui para a resiliência do sistema elétrico ao superar o gargalo da rotulagem manual em cenários de Big Data.*

Abstract. *The modernization of electrical grids generates massive volumes of unlabeled disturbance data, making manual analysis unfeasible. This study aims to automatically characterize these events in distribution substations using real data without human supervision. The computational solution integrates Deep Learning via Convolutional Autoencoders for feature extraction and the K-Means algorithm for signal clustering. The research will process oscillography from substations Sub3 and Sub8, covering normalization, neural network training, and validation of formed groups via silhouette metrics. It is expected to demonstrate the feasibility of autonomous segregation of events such as sags and swells, filtering critical anomalies to aid decision-making. The work contributes to power system resilience by overcoming the manual labeling bottleneck in Big Data scenarios.*

1. Introdução

A modernização dos sistemas de energia elétrica e a transição contínua para o conceito de *Smart Grids* resultaram em uma integração massiva de dispositivos eletrônicos inteligentes, fontes de energia renovável e sistemas de monitoramento avançado (Ukil e Zivanovic, 2014) (Mishra, Subudhi e Jain, 2019). Embora essa evolução tecnológica ofereça maior observabilidade da rede, ela também introduziu novos desafios, particularmente no que tange à Qualidade de Energia (PQ). A proliferação de cargas não lineares e a intermitência de fontes renováveis aumentaram a complexidade das

perturbações elétricas, tornando a detecção e classificação desses eventos uma tarefa crítica para garantir a confiabilidade e a eficiência do sistema (Rodriguez *et al.*, 2020) (Sekar, Sendil kumar e Karthick, 2020).

Atualmente, os registradores digitais de perturbações (DFRs) e medidores de qualidade de energia geram volumes massivos de dados oscilográficos com alta resolução (Ukil e Zivanovic, 2014). No entanto, a transformação desses dados brutos em informações úteis ("conhecimento") representa um gargalo significativo para as concessionárias (Ukil e Zivanovic, 2014). A grande maioria desses registros não possui rótulos — ou seja, a causa e o tipo da perturbação são desconhecidos no momento da coleta — e o volume de dados é excessivo para ser processado manualmente por operadores humanos (Islam *et al.*, 2023). Além disso, a análise manual é um processo tedioso, impreciso e dependente da disponibilidade de especialistas o que, muitas vezes resulta em dados críticos sendo ignorados ou descartados (Shinde, Sonwane e Munje, 2019) (Mishra, Subudhi e Jain, 2019).

As abordagens tradicionais de processamento de sinais, como a Transformada de Fourier (FT) ou a Transformada Wavelet (WT) isolada, embora amplamente utilizadas, apresentam limitações quanto à extração de características em cenários ruidosos e dependem frequentemente de limiares fixos ou seleção manual de atributos (Mishra, Subudhi e Jain, 2019) (Sekar, Sendil kumar e Karthick, 2020). Diante da escassez de dados rotulados e da ausência de supervisão especializada constante, técnicas de Inteligência Artificial (IA), especificamente o Aprendizado de Máquina Não Supervisionado, emergem como soluções promissoras (Shinde, Sonwane e Munje, 2019) (Almasoudi, 2023). Algoritmos de agrupamento (*clustering*), como o *K-Means*, permitem identificar automaticamente padrões ocultos e segregar eventos de qualidade de energia (como afundamentos, elevações e interrupções) sem a necessidade de treinamento prévio com rótulos (Islam *et al.*, 2023).

Para aumentar a robustez dessa análise, a literatura recente propõe o uso de *Deep Learning*, como *Autoencoders* Convolucionais (CAE), para realizar a extração automática de características e a redução de dimensionalidade dos sinais antes do agrupamento (Rodriguez *et al.*, 2020) (Islam *et al.*, 2023). Essa abordagem híbrida elimina a necessidade de engenharia manual de características e melhora a imunidade a ruídos, permitindo que o sistema filtre anomalias e eventos de interesse de forma autônoma (Mishra, Subudhi e Jain, 2019) (Islam *et al.*, 2023).

Neste contexto, este trabalho propõe a aplicação de técnicas de agrupamento e aprendizado profundo para a caracterização automática de perturbações elétricas, utilizando uma base de dados reais coletada nas subestações Sub3 e Sub8. O objetivo é demonstrar como algoritmos não supervisionados podem estruturar dados desconhecidos e auxiliar na tomada de decisão operacional, superando a barreira da falta de especialistas e contribuindo para a resiliência do sistema elétrico frente a falhas e eventos imprevistos (Almasoudi, 2023) (Diahovchenko e Keane, 2025).

2. Fundamentação teórica

Esta seção apresenta os conceitos fundamentais sobre a Qualidade de Energia (PQ), bem como as técnicas de Inteligência Artificial adotadas para o processamento de grandes volumes de dados não rotulados: o algoritmo *K-Means* e os *Autoencoders*

Convolucionais. A escolha dessas teorias justifica-se pela necessidade de automatizar a análise de perturbações em cenários onde a classificação manual é inviável.

2.1. Perturbações na Qualidade de Energia

A qualidade de energia refere-se à conformidade da forma de onda de tensão, corrente e frequência com padrões estabelecidos. Desvios nestes parâmetros são classificados como fenômenos eletromagnéticos. De acordo com a revisão de 2019 da norma IEEE Std 1159, esses fenômenos são categorizados com base em seu conteúdo espectral e duração, alinhando-se aos conceitos de compatibilidade eletromagnética. As categorias principais utilizadas pela comunidade de qualidade de energia incluem: Transientes (Impulsivos e Oscilatórios), Variações de Curta Duração (que englobam os Afundamentos, também denominados Dips ou Sags, Elevações ou Swells, e Interrupções) e Distorção da Forma de Onda (incluindo Harmônicos e Ruído) (IEEE, 2019).

A análise desses eventos é crítica, pois perturbações podem causar falhas em equipamentos sensíveis, perdas econômicas e instabilidade na rede. No entanto, a modernização das redes (Smart Grids) resultou em um aumento exponencial no volume de dados registrados por medidores digitais, criando um cenário de *Big Data* onde a maioria dos registros não possui rótulos e a análise manual por especialistas tornou-se impraticável (Ukil e Zivanovic, 2014), (Islam *et al.*, 2023).

2.2. Aprendizado de Máquina Não Supervisionado: *K-Means*

Para lidar com a ausência de dados rotulados, a literatura aponta o uso de aprendizado não supervisionado. O algoritmo de clusterização *K-Means* é uma das técnicas mais consolidadas para agrupar dados com base em similaridade de características, sem a necessidade de supervisão humana prévia (Shinde, Sonwane e Munje, 2019).

O algoritmo K-Means tem como objetivo particionar um conjunto de dados em k grupos (clusters), buscando minimizar a soma das distâncias quadráticas entre cada ponto e o centroide de seu respectivo grupo, definido como a média das amostras que o compõem (Teeuwsen, 2005). Seu funcionamento é iterativo: inicialmente, k centroides são definidos de forma arbitrária; em seguida, cada amostra é associada ao centroide mais próximo, geralmente considerando a distância euclidiana. Após essa atribuição, os centroides são atualizados com base na média das amostras vinculadas, e o processo se repete até que o critério de convergência seja atingido (Shinde, Sonwane e Munje, 2019; Teeuwsen, 2005).

A validação da qualidade dos *clusters* em cenários não supervisionados é frequentemente realizada por métricas como a pontuação de silhueta (Silhouette Score) ou o método do cotovelo (Elbow Method), que avaliam a coesão interna e a separação entre os grupos (Islam *et al.*, 2023).

2.3. *Deep Learning* e *Autoencoders* Convolucionais

Embora o *K-Means* seja eficaz, seu desempenho diminui quando aplicado diretamente a dados de alta dimensão, como formas de ondas brutas de tensão. Para mitigar isso, utiliza-se a técnica de *Deep Learning* conhecida como *Autoencoder* (AE) para redução de dimensionalidade e extração de características (Islam *et al.*, 2023), (Rodriguez *et al.*, 2020).

Um Autoencoder é uma rede neural projetada para reproduzir sua entrada na saída por meio de um processo de codificação e decodificação. Na etapa de codificação

(encoder), os dados de entrada são comprimidos em uma representação latente de menor dimensão, que retém os atributos mais significativos do sinal. Na etapa de decodificação (decoder), o modelo reconstrói o sinal original a partir dessa representação, buscando minimizar o erro de reconstrução (Islam et al., 2023; Rodriguez et al., 2020). Quando são utilizadas camadas convolucionais (CAE – Convolutional Autoencoder), o modelo adquire a capacidade de filtrar ruídos e capturar padrões temporais complexos das perturbações elétricas de forma mais eficiente que a extração manual de características (Almasoudi, 2023; Islam et al., 2023). A integração do CAE para extração de atributos com o algoritmo K-Means para agrupamento constitui, portanto, uma abordagem robusta para a classificação de dados experimentais reais e ruidosos.

3. Trabalhos relacionados

A aplicação de técnicas de Inteligência Artificial para a análise de Qualidade de Energia (PQ) tem sido amplamente explorada na literatura recente, com abordagens que variam desde sistemas especialistas baseados em regras até redes neurais profundas. Foi conduzida uma pesquisa direcionada a métodos de detecção e classificação de perturbações, permitindo situar a presente proposta frente ao estado da arte.

Mishra, Subudhi e Jain (2019) propuseram um modelo baseado em Redes Neurais Convolucionais (CNN) para classificar 16 tipos de perturbações de energia, incluindo eventos simples e complexos. O estudo utilizou a Transformada Wavelet Contínua (CWT) para converter sinais unidimensionais em representações de imagem, que serviram de entrada para a CNN. Embora o modelo tenha demonstrado alta imunidade a ruídos e precisão superior aos métodos tradicionais, a abordagem foi supervisionada, dependendo de um vasto conjunto de dados sintéticos rotulados para o treinamento, o que nem sempre reflete a realidade de dados de campo não rotulados.

Em uma linha semelhante, Rodriguez *at al* (2020) (Rodriguez *et al.*, 2020) desenvolveram uma abordagem híbrida utilizando *Autoencoders* Convolucionais (CAE) para redução de dimensionalidade, seguidos por Redes Neurais Recorrentes (RNN) do tipo *Long Short-Term Memory* (LSTM) empilhadas para a classificação. O estudo destacou a capacidade dos CAEs em comprimir o tamanho do sinal mantendo características dinâmicas relevantes, o que reduziu significativamente o tempo de processamento. Contudo, assim como em Rodriguez *at al.* (2020), a validação foi realizada majoritariamente com dados sintéticos gerados a partir de modelos matemáticos parametrizados, mantendo a dependência de rótulos prévios para a etapa de classificação.

Abordando a questão da falta de rótulos, Shinde, Sowane e Munje (2019) exploraram o uso de aprendizado de máquina não supervisionado, especificamente o algoritmo *K-Means*, para agrupar eventos de afundamento, elevação e interrupção. O trabalho demonstrou a viabilidade de agrupar amostras semelhantes sem treinamento supervisionado prévio. No entanto, a extração de características baseou-se em atributos tradicionais, que podem não capturar a complexidade de perturbações não lineares ou transitórios de alta frequência presentes em redes modernas.

Mais recentemente, Islam *et al.* (2023) apresentaram uma técnica não supervisionada que combina *Deep Learning* e clusterização, utilizando CAEs para extração automática de características e *K-Means* para o agrupamento. O estudo inovou ao aplicar o método em dados de campo reais de uma rede de distribuição, utilizando a visualização t-SNE para interpretar os *clusters*. A principal contribuição dessa abordagem

foi a capacidade de filtrar formas de onda anômalas de eventos recorrentes sem a necessidade de rotulagem massiva.

Com base nesses estudos, observa-se que abordagens envolvendo o uso de Deep Learning (Mishra, Subudhi e Jain, 2019), (Rodriguez et al., 2020) e técnicas de clusterização (Shinde, Sonwane e Munje, 2019) já se encontram bem estabelecidas na literatura. Entretanto, os estudos existentes tendem a empregar alguma forma de supervisão na etapa de caracterização dos dados. Diferentemente, o presente trabalho propõe o uso combinado da arquitetura CAE e do algoritmo K-Means, inspirado em (Islam et al., 2023), para realizar uma análise totalmente não supervisionada sobre dados provenientes de subestações, avaliando a capacidade da metodologia em identificar padrões intrínsecos em um conjunto de dados reais sem qualquer curadoria prévia.

4. Solução computacional

Este capítulo detalha a arquitetura da solução proposta, as ferramentas tecnológicas selecionadas e o pipeline de processamento de dados desenvolvido para a caracterização não supervisionada de perturbações elétricas. A metodologia computacional foi estruturada para operar em ambiente de nuvem, visando escalabilidade e reprodutibilidade.

4.1. Arquitetura da Solução

A solução foi projetada como um pipeline sequencial de aprendizado de máquina, dividido em três módulos principais: (i) Pré-processamento e Normalização; (ii) Extração de Características via *Deep Learning*; e (iii) Agrupamento e Análise. A arquitetura proposta busca transformar dados brutos de oscilografia em *clusters* de eventos significativos sem a necessidade de intervenção humana para rotulagem prévia.

O fluxo de dados inicia-se com a ingestão das séries temporais brutas provenientes das subestações transmissão de energia. Em seguida, uma Rede Neural do tipo *Autoencoder* Convolucional (CAE) é utilizada para comprimir esses sinais em um vetor de características latentes (*latent space*), reduzindo a dimensionalidade e filtrando ruídos. Por fim, o algoritmo *K-Means* é aplicado sobre esse espaço latente para segregar os eventos, conforme validado por Islam (2023) em cenários de Big Data de redes de distribuição.

4.2. Ambiente de Desenvolvimento e Tecnologias

Para a implementação da solução proposta, utilizou-se a linguagem Python (versão 3.8 ou superior) devido ao seu amplo ecossistema voltado à Ciência de Dados e Inteligência Artificial. O desenvolvimento foi realizado no ambiente Google Colab, plataforma em nuvem que disponibiliza GPUs para acelerar o treinamento das redes neurais profundas. Na construção da metodologia, empregaram-se bibliotecas como Pandas e NumPy para manipulação dos dados e operações matriciais; TensorFlow e Keras para modelagem e validação da arquitetura do Autoencoder Convolucional; Scikit-learn para o algoritmo K-Means, normalização e métricas de desempenho; e, por fim, Matplotlib e Seaborn para a visualização dos sinais elétricos, das curvas de perda e da distribuição dos clusters gerados.

4.3. *Pipeline* de Processamento e Modelagem

O desenvolvimento da solução computacional segue um fluxo rigoroso de etapas, descritas a seguir.

4.3.1. Coleta e Pré-processamento dos Dados

Os dados brutos, consistindo em formas de onda de tensão trifásica, são submetidos a uma etapa de limpeza inicial para a remoção de registros corrompidos ou com janelas de tempo inconsistentes. Dado que as redes neurais e a etapa de classificação de distúrbios são altamente sensíveis à escala dos dados de entrada, os sinais de tensão serão normalizados com base em valores por unidade (p.u.), o que é realizado dividindo-se o valor instantâneo do sinal pelo valor de pico da tensão nominal do sistema (Islam *et al.*, 2023). Diferentemente da padronização *Z-score* aplicada individualmente — que forçaria os sinais a terem variância unitária e, consequentemente, eliminaria informações críticas de magnitude —, a conversão para p.u. alinha-se às práticas e definições da norma IEEE Std 1159:2019, preservando a magnitude real da tensão remanescente (*retained voltage*) (IEEE, 2019). Esse rigor é imprescindível para que o algoritmo de agrupamento consiga diferenciar corretamente os eventos baseados em suas amplitudes absolutas, como afundamentos de tensão ou *sags* (0,1 a 0,9 p.u.) em contraposição a interrupções (< 0,1 p.u.) (IEEE, 2019).

Adicionalmente, os registros oscilográficos serão redimensionados para assegurar a uniformidade exigida na entrada do modelo de *Deep Learning*. Com base nas diretrizes da IEEE Std 1159:2019, que define as variações RMS de curta duração como fenômenos ocorrendo em intervalos de 0,5 ciclo a 1 minuto (IEEE, 2019), e apoiando-se na metodologia validada por Islam *et al*. (2023), os sinais serão janelados em segmentos temporais padronizados, abrangendo, por exemplo, de 10 a 16 ciclos da frequência fundamental (IEEE, 2019). Eventos que ultrapassem essa duração poderão ser processados através de técnicas de "janelamento" deslizante (*sliding window*), garantindo a coerência temporal e a extração fidedigna das características morfológicas pela rede neural (Junior et al., 2019).

4.3.2. Extração de Características com *Autoencoder* Convolucional (CAE)

A extração de características é conduzida por uma rede neural profunda não supervisionada baseada em um Autoencoder Convolucional. Sua arquitetura compreende um encoder, formado por camadas Conv1D seguidas de MaxPooling, responsável por reduzir a dimensionalidade dos sinais e concentrar as informações mais relevantes no vetor latente (bottleneck). Em seguida, o decoder utiliza camadas Conv1D e UpSampling para reconstruir o sinal original a partir desse vetor comprimido. O modelo foi compilado com o otimizador Adam, reconhecido pela eficiência em grandes volumes de dados e parâmetros ruidosos (Rodriguez et al., 2020), e emprega o Erro Quadrático Médio (MSE) como função de perda para minimizar a diferença entre o sinal de entrada e o reconstruído.

4.3.3. Clusterização e Visualização

Após o treinamento do CAE, a parte do *Decoder* é descartada, e o *Encoder* é utilizado para gerar os vetores de características reduzidos de toda a base de dados. Esses vetores servem de entrada para o algoritmo *K-Means*.

Para determinar o número ótimo de *clusters* (k), implementa-se o método do cotovelo (*Elbow Method*) analisando a inércia (soma dos erros quadráticos intra-*cluster*) e o coeficiente de Silhueta. Para a interpretação visual dos resultados, utiliza-se a técnica t-SNE (t-Distributed Stochastic Neighbor Embedding), que projeta os vetores de alta dimensão em um plano 2D ou 3D, permitindo a verificação visual da separabilidade das

classes de perturbações (*sags*, *swells*, harmônicos, etc.), conforme metodologia aplicada por Islam *et al*. (2023).

5. Resultados e Discussão

Esta seção apresenta a avaliação experimental da metodologia proposta. A seção está dividida na descrição da execução do *pipeline* computacional estruturado para processar o volume de dados (*Big Data*) e na discussão dos resultados obtidos através da clusterização e da curadoria semântica baseada nas normativas de qualidade de energia.

5.1. Execução do Pipeline Computacional

A execução experimental foi conduzida em ambiente de nuvem (Google Colab), utilizando processamento acelerado por GPU para o treinamento da rede neural profunda. A *pipeline* (**Figura 1**) processou um total de 327 arquivos oscilográficos brutos no formato ".mat" (MATLAB), originários das subestações de distribuição monitoradas nomeadas nesse trabalho como sub3 e sub8.

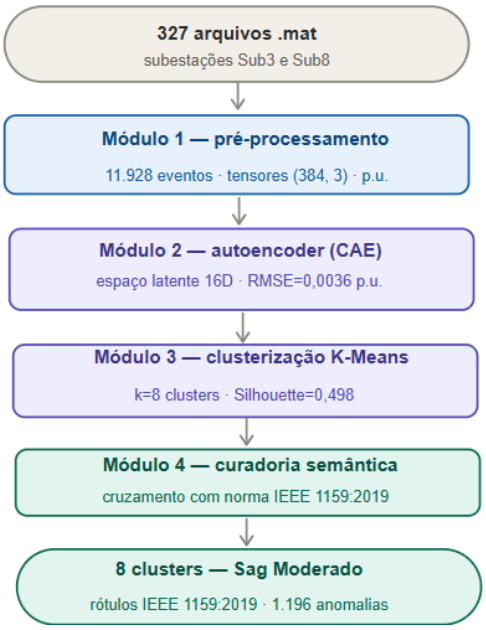

Figura 1 – Fluxograma da pipeline computacional.

Na etapa de pré-processamento (Módulo 1), as formas de onda da tensão trifásica foram extraídas e normalizadas para valores por unidade (p.u.), dividindo-se as amostras pela tensão nominal de pico do sistema. Essa abordagem garantiu a preservação da magnitude física da tensão remanescente (*retained voltage*). Utilizando uma técnica de janelamento deslizante (*sliding window*), os sinais foram padronizados em tensores tridimensionais de 384 amostras (6 ciclos à taxa de 64 amostras/ciclo), resultando em uma base de dados refinada com 11.928 eventos distintos validados para treinamento.

Para a extração de características (Módulo 2), o *Autoencoder* Convolucional (CAE) foi treinado de forma não supervisionada durante 100 épocas. O modelo demonstrou alta capacidade de compressão e retenção morfológica, reduzindo os sinais de entrada de alta dimensionalidade para um espaço latente de apenas 16 variáveis. O erro de reconstrução final (*Root Mean Squared Error* - RMSE) mediano atingiu a marca de 0,003573 p.u. (média de 0,004189 p.u.) para a base completa, com MAPE mediano de 0,93%. Esses resultados indicam que a arquitetura aprendeu com sucesso as assinaturas

dinâmicas das perturbações, filtrando ruídos irrelevantes e preservando a morfologia dos eventos.

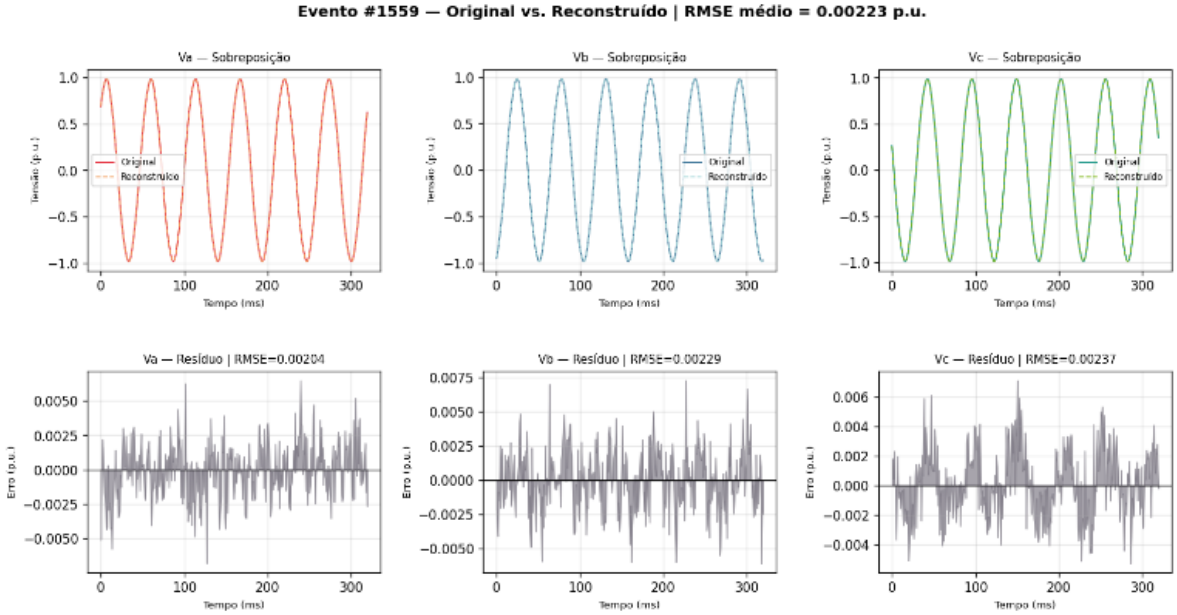

Figura 2 – Comparação entre a forma de onda original do distúrbio e o sinal reconstruído pelo *Autoencoder* Convolucional, demonstrando a preservação das características temporais essenciais.

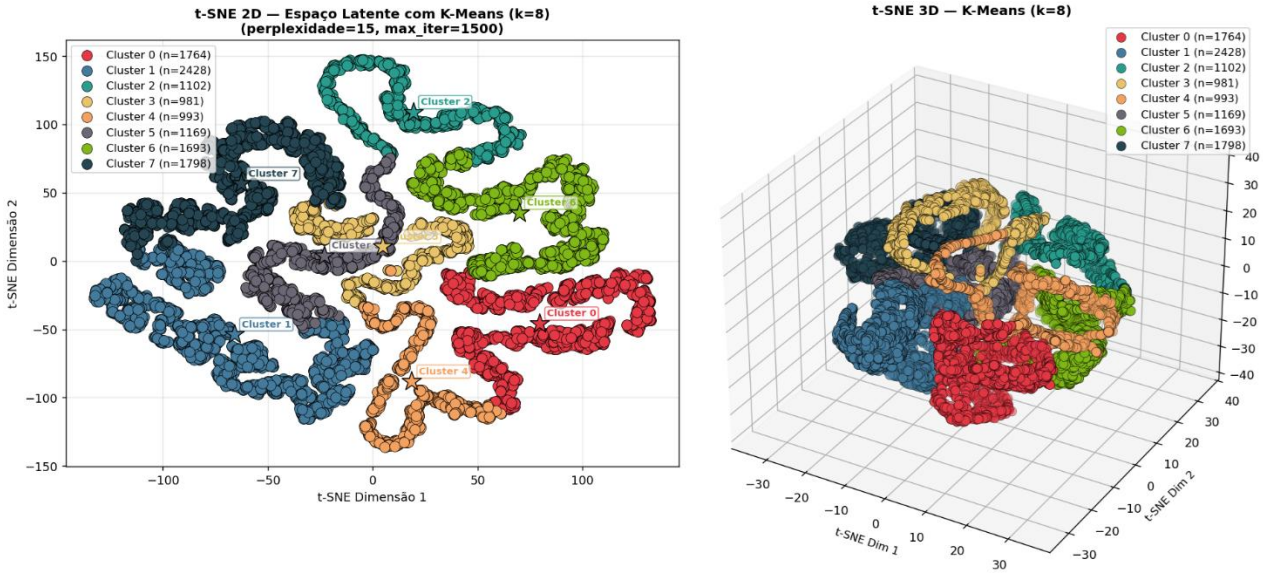

Figura 3 – Projeção de redução de dimensionalidade (t-SNE) ilustrando a separabilidade espacial dos 11.928 eventos no espaço latente em três agrupamentos principais.

Na etapa de agrupamento (Módulo 3), os vetores latentes foram padronizados via *Z-score* para adequação do cálculo de distâncias. A avaliação do número ótimo de agrupamentos (k) por meio do Método do Cotovelo (Elbow) e do coeficiente de Silhueta apontou k=8 como o particionamento matematicamente ideal, com Silhouette Score de 0,4981, Davies-Bouldin Index de 0,6381 e Calinski-Harabász Score de 11.333,32. Esses valores atestam uma separação espacial coerente para dados de campo reais, que inerentemente possuem alto nível de ruído e eventos de fronteira.

5.2 Resultados Obtidos e Curadoria Semântica

A principal contribuição analítica desta avaliação consistiu na etapa de Curadoria Semântica Híbrida (Módulo 4). Em vez de atribuir rótulos baseados puramente nas médias matemáticas dos *clusters*, o algoritmo realizou um cruzamento individualizado de cada forma de onda com as diretrizes rigorosas da norma IEEE Std 1159:2019.

A análise autônoma do sistema revelou que a separação física global entre os três *clusters* principais (ΔVrms) era de apenas 0,0076 p.u., inferior ao limiar significativo de variabilidade (0,05 p.u.). Esse diagnóstico matemático evidenciou que a quase totalidade da base de dados (cerca de 90%) é dominada por um único tipo de fenômeno macro: os Afundamentos Moderados de Tensão (Sags), com tensões remanescentes médias variando na faixa de 0,688 a 0,696 p.u. entre os oito grupos formados.

Diante da homogeneidade observada nos dados, o algoritmo K-Means agrupou os eventos principalmente com base nas fases elétricas afetadas e em variações sutis de tensão de pré-falta. Os oito clusters formados foram todos rotulados pela curadoria semântica como Sag Moderado (0,50–0,70 p.u.), com diferenciação pela fase dominante. Seis clusters apresentaram predominância da fase B e dois da fase C (clusters 3 e 7), com durações médias semelhantes em torno de 29 ms e tensões de pré-falta variando de 0,696 a 0,701 p.u. O maior grupo (Cluster 1) concentrou 2.428 eventos (20,4% da base), enquanto o menor (Cluster 3) agrupou 981 eventos (8,2%). Adicionalmente, a análise estatística prévia detectou 11 eventos de interrupção (0,1% da base), caracterizados por tensões inferiores a 0,1 p.u., os quais foram corretamente isolados pela curadoria híbrida com base nas regras da norma IEEE Std 1159:2019.

Adicionalmente, ao calcular as distâncias espaciais dos eventos em relação aos seus centróides matemáticos, o algoritmo isolou 1.196 eventos atípicos (≈ 10,0% da base) classificados como "Anomalias para Inspeção Manual". Essa separação evidencia o valor prático da IA não supervisionada no setor elétrico: o sistema foi capaz de estruturar automaticamente 90% da base que possuía comportamento repetitivo e comum, permitindo que a equipe de engenharia da concessionária foque sua atenção exclusivamente nos 10% de anomalias críticas, resolvendo o gargalo operacional imposto pelo cenário de Big Data.

6. Considerações Finais

Este trabalho demonstrou a viabilidade técnica e o valor operacional da aplicação de técnicas de Inteligência Artificial não supervisionada para a caracterização autônoma de perturbações de qualidade de energia elétrica. O *pipeline* desenvolvido, integrando *Deep Learning* (*Autoencoders* Convolucionais) e clusterização (*K-Means*), foi capaz de processar uma base de dados reais de alta complexidade contendo 11.928 registros oscilográficos não rotulados, extraídos de 327 arquivos provenientes das subestações Sub3 e Sub8.

A principal linha abordada por este estudo foi a dependência de especialistas humanos para a rotulagem de grandes volumes de dados. O *Deep Learning* atuou de forma autônoma na extração de características e redução de dimensionalidade estrutural, enquanto o módulo de inteligência baseada em regras conectou as descobertas matemáticas da IA aos limites físicos da norma IEEE Std 1159:2019. O diagnóstico final revelou uma rede de distribuição predominantemente afetada por afundamentos de tensão (*sags*) nas fases B e C, com todos os oito grupos formados enquadrados na categoria Sag

Moderado (0,50–0,70 p.u.) da norma IEEE Std 1159:2019, sinalizando um padrão sistemático de afundamentos moderados de tensão nas subestações monitoradas.

A capacidade do sistema em atuar como um "filtro de triagem" pode viabilizar sua aplicabilidade para a indústria. Ao identificar e isolar 1.196 anomalias morfológicas (≈ 10% da base), a ferramenta automatiza a etapa mais tediosa do monitoramento de *Smart Grids*, direcionando a expertise humana apenas para os eventos que de fato exigem investigação avançada.

Como perspectivas de trabalhos futuros, sugere-se a aplicação de algoritmos baseados em densidade, como o DBSCAN, visando lidar com perturbações multifatoriais e de fronteira. Adicionalmente, recomenda-se a implementação computacional desta arquitetura em dispositivos de borda (Edge Computing) acoplados aos medidores das subestações, possibilitando o monitoramento e a tomada de decisão em tempo real.

7. Referências

ALMASOUDI, F. M. Enhancing Power Grid Resilience through Real-Time Fault Detection and Remediation Using Advanced Hybrid Machine Learning Models. **Sustainability**, 2023. 15.

DIAHOVCHENKO, I.; KEANE, A. Clustering for power system stability using graph theory and electrical distance. **Sustainable Energy, Grids and Networks**, 2025. 43.

IEEE. IEEE Recommended Practice for Monitoring Electric Power Quality. **IEEE Std 1159-2019 (Revision of IEEE Std 1159-2009)**, 2019. 1-98.

ISLAM, M. M. *et al.* Unsupervised clustering of disturbances in power systems via deep convolutional autoencoders. **IEEE**, 2023.

JUNIOR, W. L. Rodrigues *et al.* A Methodology for Detection of Power Quality Disturbances in the Context of Demand Side Management. **2019 4th International Conference on Smart and Sustainable Technologies (SpliTech)**, Split, 2019. 1-6.

MISHRA, P. K.; SUBUDHI, U.; JAIN, S. Power Quality Disturbances Classification with Deep Learning Approach. **2019 International Conference on Smart Energy Systems and Technologies (SEST)**, 2019.

RODRIGUEZ, M. A. *et al.* Power Quality Disturbance Classification via Deep Convolutional Auto-Encoders and Stacked LSTM Recurrent Neural Networks. **IEEE**, 2020.

SEKAR, K.; SENDIL KUMAR, S.; KARTHICK, K. Power Quality Disturbance Detection using Machine Learning Algorithm. **IEEE**, 2020.

SHINDE, P.; SONWANE, P.; MUNJE, R. Machine Learning based Clustering for Identifying Power Quality Events, 2019.

TEEUWSEN, S. P. **Oscillatory Stability Assessment of Power Systems using Computational Intelligence**. 2005., 2005.

UKIL, A.; ZIVANOVIC, R. Automated Analysis of Power Systems Disturbance Records: Smart Grid Big Data Perspective. **2014 IEEE Innovative Smart Grid Technologies - Asia (ISGT ASIA)**, 2014.